Zadaci za domaći rad – Laboratorijske vježbe

I. Frekvencijsko preklapanje (*aliasing*)

U skladu sa predavanjima u poglavlju 2.4 knjige, dato je objašnjenje efekta preklapanja frekvencija poslije diskretizacije. U skladu sa tim tekstom, a koristeći kod dat u nastavku ponoviti rezultate iz knjige. Odabrati još dva primjera koji pokazuju da će doći do pojave aliasing-a i dva primjera kod kojih nema aliasing-a. U formi kratkog izvještaja opisati odabrane parametre i dati analizu i objašnjenje dobijenih rezultata. Za izvršavanje skripte potrebno je definisati frekvenciju kontinualnog signala **f** i frekvencije odabiranja **fs.**

```
clear all
close all
tMax = 5; % Maksimalno vrijeme trajanja signala
t = 0 : 0.0001 : tMax; % Definisanje trenutaka u kojim se izracunava
kontinualni signal
f = XXX; % Frekvencija kontinualnog signala

fs = XXX; % Definisanje frekvencije odabiranja
ts = 0 : 1/fs : tMax; % Definisanje diskretnih trenutaka na osnovu
frekvencije odabiranja

fcontinous = cos(2 * pi * f * t); % Kontinualna funkcija
fsampled = cos(2 * pi * f * ts); % Diskretizovana funkcija

% Crtanje funkcija
figure
hold on
set(gca, 'fontsize', 14, 'fontweight', 'bold');
plot(t, fcontinous, 'b', 'linewidth', 2);
plot(ts, fsampled, 'ko', 'linewidth', 2);

% Provjera da li je frekvencija odabiranja adekvatno odabrana
% i da li postoji aliasing
if (fs < 2 * f)
    flag = 1;
    m = 0
    while (flag)
        fAliasing = abs(f - m * fs);
        if (fAliasing <= fs/2)
            flag = 0;
        else
            m = m + 1;
        end
    end
    plot(t, cos(2 * pi * fAliasing * t), 'r', 'linewidth', 2);
    title(['Aliasing frekvencija ' num2str(fAliasing) ' Hz']);
else
    title('Ne postoji aliasing frekvencija');
end
ylim([-1.5 1.5])
grid on
```

```
xlabel('Vrijeme [s]')
```

II. Predfiltri (*antialiasing* filtri)

U skladu sa predavanjima u poglavlju 2.5 knjige, dato je objašnjenje efekta visokofrekvencijskih komponenti na proces diskretizacije, te primjenu filtara za rješavanje pomenutih problema. Potrebno je realizovati simulink model za analizu i testiranje pomenutog problema. Model treba da sadrži elemente sa slike.

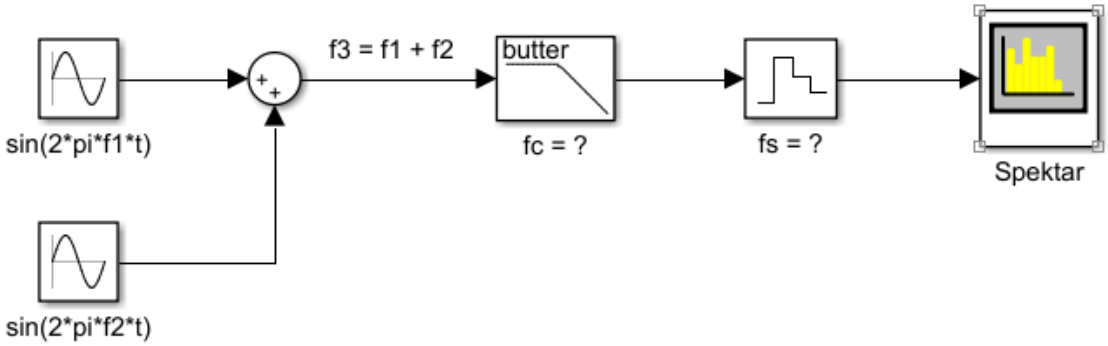

Blokovi ulaznih signala se nalaze u simulink biblioteci *Sources*, blok kola zadrške nultog reda (fs = ?) u biblioteci *Discrete* (potrebno je obratiti pažnju da se u bloku zadaje period odabiranja a ne frekvencija), blok filtra (fc=?) u biblioteci *DSP System Toolbox→Filtering→Filter Implementations*, gdje se bira *Analog Filter Design* i podešava samo *Passband edge frequency* parametar, dok ostali zadržavaju podrazumijevane vrijednosti. Blok Spektar predstavlja blok *Spectrum Analyzer* iz biblioteke *Sinks*. Moguće je korisiti i druge komponente ukoliko smatrate da su pogodnije. Potrebno je:

a) Realizovati simulink model sa slike
b) Definisati frekvencije signala **f1** = 100Hz i **f2** = 160Hz.
c) Signal **f3** koji predstavlja zbir signala **f1** i **f2** propušta se kroz filtar nakon čega se signal na izlazu filtra diskretizuje frekvencijom odabiranja **fs**. Nakon diskretizacije prikazuje se spektar diskretizovanog signala. Potrebno je odrediti graničnu frekvenciju filtra tako da propušta signal **f3** u cjelosti, zatim da propušta samo signal **f1** i na kraju samo signal **f2**. Nakon svakog odabira granične frekvencije filtra odabrati adekvatnu periodu odabiranja **fs**. Rezultate prikazati u analizatoru spektra i dati kratku analizu i objašnjenje dobijenih rezultata.
d) Modifikovati model tako da se na proizvoljno odabran ulazni signal dodaje šum (visokofrekvencijska komponenta). Odabrati adekvatnu kombinaciju granične frekvencije **fc** i frekvencije odabiranja **fs** tako da se na analizatoru spektra vidi izvorni signal (filtar ne filtrira dodani šum) i da se vidi signal bez šuma (filtar ukljanja šum). Komentarisati izbor parametara **fc** i **fs** za oba slučaja i objasniti dobijene rezultate.

III. $Z,\ Z^{-1}, Z_m$ transformacija

S obzirom da smo se u prethodim vježbama najviše susretali sa Z transformacijom i inverznom Z transformacijom obradićemo osnovne komande programskog okruženja Matlab za određivanje funkcija diskretnog prenosa sistema zadatih funkcijama u vremenskom domenu ili njihovim Laplasovim transformacijama.

Definisanje funkcije prenosa u Matlab-u se može realizovati na više načina a neki od uobičajenih su dati u nastavku. Pretpostavimo da je objekat upravljanja opisan funkcijom prenosa čija je Laplasova transformacija data sa

$$G(\mathrm{s}) = \frac{1}{\mathrm{s}(\mathrm{s}+1)}$$

Ova funkcija prenosa se u Matlab-u može definisati kao u nastavku. Rezultati su prikazani u dvije kolone od kojih svaka prikazuje po jedan način definisanja funkcije prenosa.

```
>> s = tf('s');

>> F_s = 1/(s*(s + 1));
>> F_s =
    1
  -------
  s^2 + s
```

```
>> num = [1]; %zadavanje koeficijenata polinoma u brojiocu
>> den = [1 1 0]; %zadavanje koeficijenata polinoma u imeniocu
>> F_s = tf(num, den)
>> F_s =
    1
  -------
  s^2 + s
```

Za sisteme sa transportnim kašnjenjem (npr. Td = 1.2s) funkcija prenosa se definiše kao

```
>> s = tf('s');

>> F_s = = (1/(s*(s+1)))*exp(-1.2*s)
>> F_s =
                  1
  exp(-1.2*s) *  -------
                 s^2 + s
```

```
>> num = [1];
>> den = [1 1 0];
>> F_s = tf(num, den, 'InputDelay', 1.2)
>> F_s =
                  1
  exp(-1.2*s) *  -------
                 s^2 + s
```

Nakon dobijanja Laplasove transformacije funkcije prenosa možemo primijeniti Z transformaciju pozivom fukcije c2d(F_s, T), gdje je F_s dobijena funkcija prenosa, a T perioda odabiranja. Funkcija c2d(F_s, T) podržava izračunavanje Z transformacije primjenom više metoda, od kojih je podrazumijevana metoda koja u izračunavanje Z transformacije uključuje kolo zadrške nultog reda. Funkcija se može pozvati i kao c2d(F_s, T, 'ZOH'), mada kao što je naglašeno ako se i ne navede naziv metoda podrazumijevani metod je upravo ZOH. Detalje poziva i mogućnosti odabira parametara date funkcije možete pogledati u Matlab Help-u. Slijede pozivi date funkcije za usvojenu periodu odmjeravanja T=1s.

```
>> T = 1;
>> F_z = c2d(F_s, T)
```

Inverzna Z transformacija se dobija pozivom funkcije d2c(F_z)

```
F_s = d2c(F_z)
```

```
>> F_z =

   0.3679 z + 0.2642
  ----------------------
  z^2 - 1.368 z + 0.3679

Sample time: 1 seconds
Discrete-time transfer
function.
```

```
>> F_s =

        1
  ------------------
  s^2 + s - 2.22e-16

Continuous-time transfer function.
```

Za sisteme sa transportnim kašnjenjem se zapravo primjenjuje modifikovana Z transformacija, bez potrebe da se definiše parametar ***m***, gdje je funkcija F_s funkcija koja sadrži transportno kašnjenje.

```
>> T = 1;
>> F_z = c2d(F_s, T)
>> F_z =

                0.2493 z^2 + 0.3749 z + 0.007874
  z^(-2) *    --------------------------------
                  z^2 - 1.368 z + 0.3679

Sample time: 1 seconds
Discrete-time transfer function.
```

Inverzna Z transformacija d2c(F_z)

```
F_s = d2c(F_z)
>> F_s =

                0.2493 s^2 + 0.8 s + 1
  exp(-2*s) *   ----------------------
                  s^2 + s + 2.22e-16

Continuous-time transfer function.
```

Inverzna Z transformacija funkcije diskretnog prenosa koja je dobijena diskretizacijom funkcije prenosa sa kašnjenjem ne daje tačnu funkciju prenosa nakon poziva funkcije d2c(F_z). Ovaj problem se najčešće javlja kada period odmjeravanja nije adekvatno izabran za zadato transportno kašnjenje sistema.
Z transformacija i inverzna Z transformacija se mogu računati i simbolički, primjenom funkcija **ztrans** i **iztrans**, kao što slijedi

```
syms s t z
F_s(s) = 1/(s*(s+1)) % Laplasova transformacija
f_t(t) = ilaplace(F_s) % Inverzna Laplasova transformacija
F_z(z) = ztrans(f_t) % Z trasformacija
f_t2(t) = iztrans(F_z) % Inverzna Z trasformacija
```

Provjeriti kakav će biti rezultat u matlabu.

Pored funkcije prenosa na isti način se vrši i diskretizacija sistema opisanog modelom u prostoru stanja kao

```
>> A = [0 1;-0.5 -1.5];
>> B = [0; 1];
>> C = [2 1];
>> D = 0;
>> Sys_c = ss(A,B,C,D)
>> T = 0.5;
```

```
>> Sys_d = c2d(Sys_c, T)
```

Provjeriti rezultat sa rješenjem zadatka koji je rađen na prethodnim vježbama.